

AGH UNIVERSITY OF SCIENCE AND TECHNOLOGY

WYDZIAŁ FIZYKI I INFORMATYKI STOSOWANEJ
KIERUNEK STUDIÓW: FIZYKA TECHNICZNA



METODY MONTE CARLO

Laboratorium 2

Generatory liczb pseudolosowych o zadanym rozkładzie w jednym wymiarze

zrealizował
Przemysław Ryś

Kraków, 4 Marzec 2024

1 Opis zagadnienia

Na zajęciach skonstruowaliśmy generator jednowymiarowy o funkcji gęstości prawdopodobieństwa $f(x) = \frac{1+x-x^3}{4}$ dla $x \in [0, 1]$ oraz dystrybuancie $F(x) = \frac{x^2}{4} + \frac{x^4}{5}$ dla $x \in [0, 1]$.

Do generowania liczb pseudolosowych użyjemy schematów dla:

- a) Rozkładu złożonego,
- b) Łańcucha Markowa,
- c) Metody eliminacji.

1.1 Rozkład złożony

Dystrybuanta rozkładu jest wielomianem, więc możemy spróbować zapisać ją w postaci rozkładu złożonego:

$$F(x) = \sum_{i=1}^n g_i H_i(x),$$

gdzie g_i to dystrybuanta rozkładu dyskretnego, a $H_i(x)$ to dystrybuanty rozkładów podlegających superpozycji. Musimy przekształcić $F(x)$ do postaci akceptowalnej:

$$F(x) = \frac{1}{4}x + \frac{2x^2 - x^4}{5},$$

skąd odczytujemy:

$$g_1 = \frac{4}{5}, \quad H_1 = x,$$
$$g_2 = \frac{1}{5}, \quad H_2 = 2x^2 - x^4.$$

Teraz należy znaleźć funkcje odwrotne H_1 i H_2 aby otrzymać liczbę losową $X = x$. H_1 jest liniowa, więc od razu dostajemy:

$$H_1(x) = x = U \sim U(0, 1).$$

Dla H_2 :

$$H_2(x) = 2x^2 - x^4 = U \sim U(0, 1).$$

Mamy równanie 4 stopnia:

$$x^4 - 2x^2 + U = 0,$$

które rozwiązujemy podstawiając $y = x^2$ i rozwiązując równanie kwadratowe:

$$y^2 - 2y + U = 0, \quad y_1, y_2 = 1 \pm \sqrt{1 - U}.$$

Ponieważ $y_1 > 1$ (pamiętamy, że generujemy $x \in [0, 1]$), wybieramy y_2 i liczymy x :

$$x = \sqrt{1 - \sqrt{1 - U}}.$$

1.2 Łańcuch Markowa

W tej metodzie generujemy ciąg $\{X_0, X_1, X_2, \dots\}$, gdzie związek pomiędzy ostatnim elementem X_i a kolejnym X_{i+1} określamy na podstawie prawdopodobieństwa przejścia, które spełnia warunek detailed balance:

$$\frac{1}{\Delta} T(X_{i+1}|X_i) = \frac{1}{2\Delta},$$

i prawdopodobieństwa akceptacji nowego stanu (liczby):

$$p_{\text{acc}} = \min \left\{ 1, \frac{T(X_i|X_{i+1})f(X_{i+1})}{T(X_{i+1}|X_i)f(X_i)} \right\}.$$

Algorytm Metropolisa generowania nowego elementu w łańcuchu:

$$\begin{cases} x_{\text{new}} = X_i + (2U_1 - 1)\Delta, & \text{gdy } x_{\text{new}} \in [0, 1] \text{ i } U_2 p_{\text{acc}}, \\ X_{i+1} = X_i, & \text{w przeciwnym przypadku.} \end{cases}$$

1.3 Metoda eliminacji

W metodzie tej wykorzystujemy funkcję gęstości prawdopodobieństwa $f(x)$, którą ograniczamy od góry inną funkcją o rozkładzie $g(x)$, dla której dysponujemy generatorem G . Algorytm generowania ciągu liczb metodą eliminacji:

$$\begin{aligned} &U_1 \sim U(0, 1), \\ &G_2 \sim G, \quad \text{np. } G = 1.15 \cdot U(0, 1), \\ &\begin{cases} G_2 f(U_1) \Rightarrow X = U_1, \\ G_2 > f(U_1) \Rightarrow \text{losujemy nową parę } U_1, G_2. \end{cases} \end{aligned}$$

1.4 Test χ^2

Test χ^2 jest jednym z najczęściej stosowanych testów statystycznych służących do oceny zgodności pomiędzy obserwowanymi danymi a oczekiwanym rozkładem. Jest to test nielosowy, który pozwala zbadać, czy rozkład empiryczny danych różni się istotnie od założonego teoretycznego rozkładu.

Wartość statystyki testowej dla testu χ^2 wyraża się wzorem:

$$\chi_{k-1}^2 = \sum_{i=1}^k \frac{(n_i - p_i N)^2}{p_i N} \quad (1)$$

gdzie:

- k - liczba przedziałów (binów) w analizowanym zbiorze danych,
- p_i - prawdopodobieństwo, że zmienna losowa znajdzie się w przedziale i -tym (do wyznaczenia używa się dystrybucji),
- n_i - ilość obserwacji (liczb pseudolosowych), które znalazły się w i -tym przedziale,
- N - całkowita ilość obserwacji.

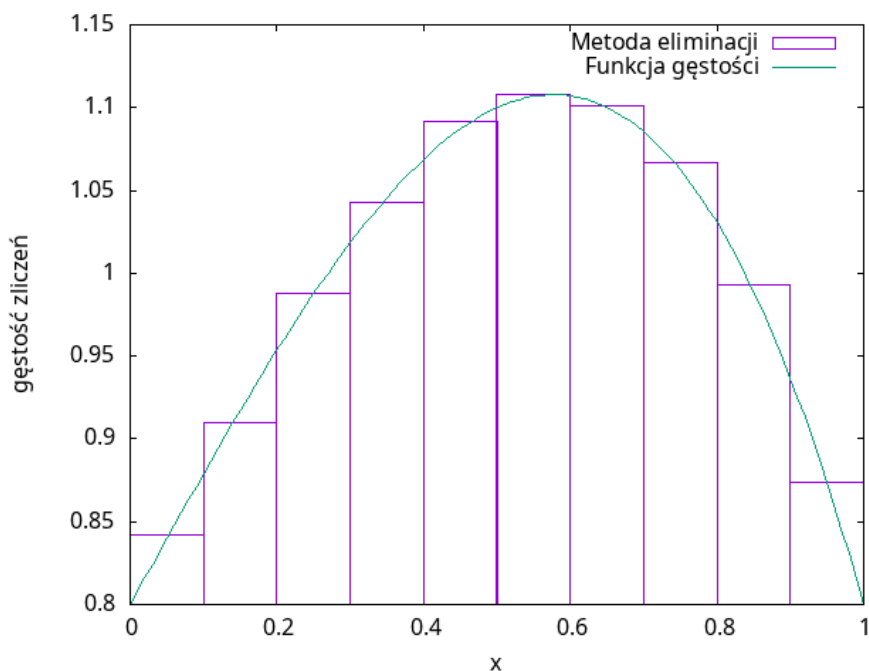
Statystyka χ^2 porównywana jest z wartością graniczną z rozkładu χ^2 z $k - 1$ stopniami swobody. Na podstawie porównania uzyskanej wartości χ^2 z wartością graniczną można stwierdzić, czy hipoteza zerowa (H_0), zakładająca zgodność danych z teoretycznym rozkładem $F(x)$, jest odrzucana czy nie.

Przyjmując poziom istotności równy $\alpha = 0.05$, odrzucamy hipotezę H_0 , jeśli wartość χ^2 przekracza odpowiednią wartość graniczną dla $k - 1$ stopni swobody przy danym poziomie istotności.

2 Wyniki

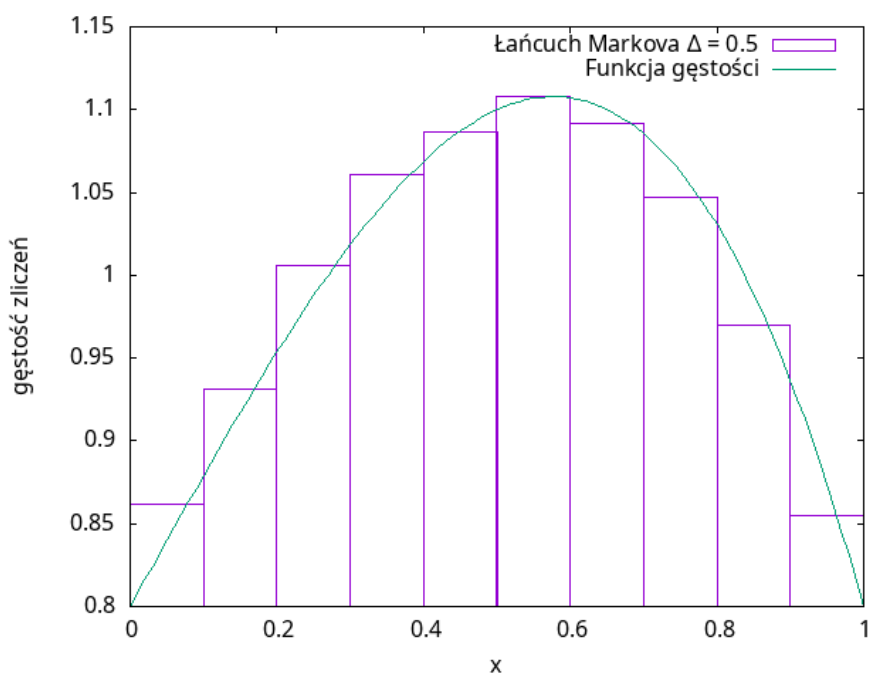
Histogramy w porównaniu z krzywą teoretyczną

Dla każdej z metod generacji liczb pseudolosowych wygenerowano histogramy danych w porównaniu z odpowiadającą im krzywą teoretyczną w programie gnuplot.




Rys. 1: Histogram liczb pseudolosowych generowanych metodą eliminacji wraz z naniesioną krzywą teoretyczną gęstości prawdopodobieństwa

Dla metody złożonej zauważamy, że histogram danych pokrywa się w przybliżeniu z krzywą teoretyczną, co sugeruje, że dane generowane tą metodą są zgodne z oczekiwanym rozkładem.



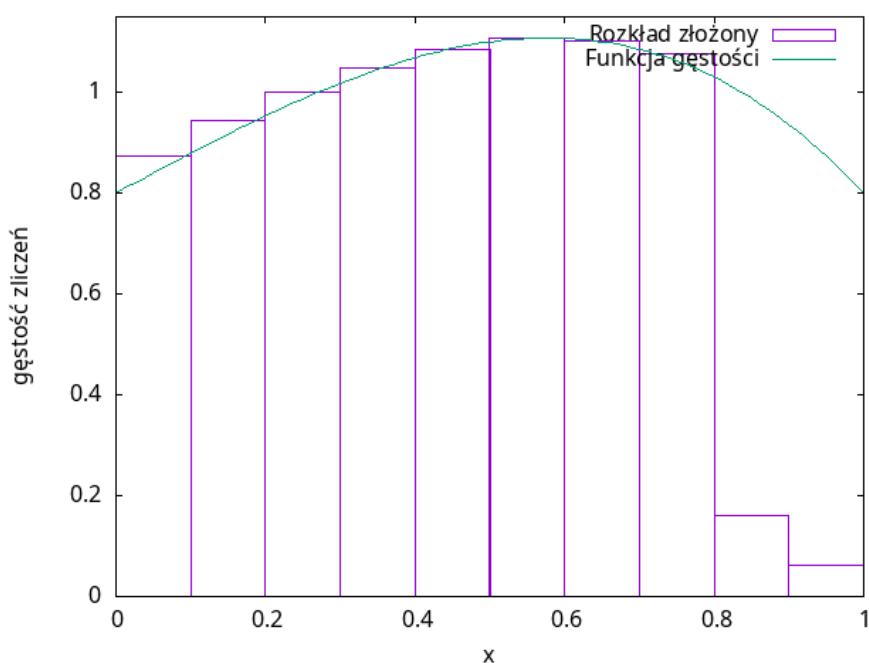
Rys. 2: Histogram liczb pseudolosowych generowanych metodą łańcucha Markowa z parametrem $\Delta = 0.5$ wraz z naniesioną krzywą teoretyczną gęstości prawdopodobieństwa

Dla metody Łańcucha Markowa z $\Delta = 0.5$, histogram danych również dobrze odwzorowuje krzywą teoretyczną, co sugeruje, że generowane dane są zgodne z oczekiwanym rozkładem. W porównaniu z metodą rozkładu złożonego, wyższe stają się słupki dla mniejszych wartości x .



Rys. 3: Histogram liczb pseudolosowych generowanych metodą łańcucha Markowa z parametrem $\Delta = 0.05$ wraz z naniesioną krzywą teoretyczną gęstości prawdopodobieństwa

Dla metody Łańcucha Markowa z $\Delta = 0.05$, obserwujemy podobne zachowanie histogramu danych w stosunku do krzywej teoretycznej. W porównaniu z tą samą metodą dla parametru $\Delta = 0.0$, słupki z lewej strony wychodzą ponad wartości krzywej teoretycznej, co sprawia, że wylosowany ciąg staje się mniej efektywny względem oczekiwań.



Rys. 4: Histogram liczb pseudolosowych generowanych metodą rozkładu złożonego wraz z naniesioną krzywą teoretyczną gęstości prawdopodobieństwa

Dla metody Eliminacji, histogram danych również dobrze odzwierciedla oczekiwaną krzywą teoretyczną, ale do pewnego momentu. Prawdopodobnie związane jest to z popełnionym w programie błędem, niemniej autor nie był w stanie go zlokalizować.

Wyniki testu χ^2

Dla każdej metody wykonano test χ^2 i porównano uzyskane wyniki z wartością graniczną rozkładu, przyjmując poziom istotności równy $\alpha = 0.05$. Wartość statystyki testowej dla $k - 1$ stopni swobody obliczono ze wzoru 1.

Poniżej przedstawiono otrzymane wyniki testu χ^2 dla poszczególnych metod:

χ^2 dla metody złożonej:	168969
χ^2 dla metody Łańcucha Markova Delta = 0.5:	221.339
χ^2 dla metody Łańcucha Markova Delta = 0.05:	1087.99
χ^2 dla metody Eliminacji:	14.1666
Wartość graniczna χ^2 :	16.919

Na podstawie porównania uzyskanych wartości χ^2 z wartością graniczną można stwierdzić:

- Hipoteza H_0 dla metody złożonej zostaje odrzucona.
- Hipoteza H_0 dla metody Łańcucha Markova Delta = 0.5 zostaje odrzucona.
- Hipoteza H_0 dla metody Łańcucha Markova Delta = 0.05 zostaje odrzucona.
- Hipoteza H_0 dla metody Eliminacji nie zostaje odrzucona.

3 Wnioski

Metoda złożona oraz metoda Łańcucha Markowa dla $\Delta = 0.5$ generują próbki, których rozkłady istotnie różnią się od teoretycznego rozkładu $F(x)$. Metoda Łańcucha Markowa dla $\Delta = 0.05$ daje jeszcze bardziej odległe od teoretycznego rozkładu próbki niż poprzednie metody, co może wskazywać na większą niestabilność tej metody dla mniejszych wartości Δ . Metoda Eliminacji wydaje się być najbardziej zbliżona do teoretycznego rozkładu $F(x)$, ponieważ generowane próbki mają znacznie mniejszą wartość statystyki testowej χ^2 i nie ma podstaw do odrzucenia hipotezy zerowej H_0 . Wybór odpowiedniej metody generacji próbek powinien być uzależniony od konkretnego zastosowania i wymagań dotyczących jakości generowanych próbek.